

**МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ**
**Ордена Трудового Красного Знамени федеральное государственное бюджетное
образовательное учреждение высшего образования**
«Московский технический университет связи и информатики»

Кафедра Программная инженерия

ОТЧЕТ
по учебной практике(технологической)

Выполнил студент группы БПИ2403

Казанцев Арсений Александрович

Проверила: Мосева А. С.

Москва
2026

ВВЕДЕНИЕ

В период с 23.06.2026 по 06.07.2026 была пройдена учебная практика по разработке программного обеспечения. В рамках практики выполнялась роль инженера-разработчика серверной части (Backend Engineer) в командном проекте интеллектуальной поисковой системы по внутренней базе знаний университета. Целью практики было получение практических навыков проектирования и реализации REST API микросервисного веб-приложения на FastAPI, интеграции с поисковым движком Elasticsearch и реляционной базой данных PostgreSQL, реализации бизнес-логики обработки документов (парсинг, разбиение на чанки, индексация) и полнотекстового поиска с ранжированием результатов.

ЭТАП 1: Инициализация приложения и реализация загрузки документов (23.06.2026 – 24.06.2026)

Период: 2 дня

***Задание:** Изучение технической документации и OpenAPI-спецификаций, инициализация FastAPI-приложения и реализация эндпоинта загрузки документов с валидацией.*

Содержание работы: Были изучены цели и задачи проекта, микросервисная архитектура приложения и распределение обязанностей в команде. Инициализировано приложение на фреймворке FastAPI: настроена точка входа main.py, конфигурация через pydantic-settings и подключение к PostgreSQL средствами асинхронного SQLAlchemy. Реализован REST API эндпоинт POST /api/v1/documents/upload для загрузки файлов. Разработан модуль валидации (file_validation): проверка формата (PDF, DOCX) и размера (не более 20 МБ) с возвратом HTTP 400 и описанием ошибки при несоответствии. Для каждого загружаемого документа генерируется

уникальный идентификатор UUID, метаданные сохраняются в БД (BE-01, BE-02, BE-03).

ЭТАП 2: Извлечение текста из документов и разбиение на чанки (25.06.2026 – 26.06.2026)

Период: 2 дня

***Задание:** Реализация модулей извлечения текста из PDF- и DOCX-документов и сегментации извлечённого текста.*

Содержание работы: Разработан сервис извлечения текста (document_parser) с использованием библиотеки pdfplumber для PDF-документов и python-docx для DOCX. Обеспечено сохранение номеров страниц для корректной навигации по результатам поиска. Реализован модуль сегментации (chunker): извлечённый текст разбивается на чанки по 1000 символов с перекрытием в 100 символов между соседними сегментами, что повышает полноту поиска на границах фрагментов. Проведена обработка краевых случаев — пустые файлы, документы с нарушенным форматированием и нестандартными кодировками, для которых предусмотрен корректный перехват исключений (BE-04, BE-05).

ЭТАП 3: Интеграция с Elasticsearch и индексация документов (27.06.2026)

Период: 1 день

***Задание:** Настройка Elasticsearch с русскоязычным анализатором и реализация функции индексации чанков документов.*

Содержание работы: Настроено подключение к Elasticsearch через асинхронный клиент. Создан индекс documents с русскоязычным анализатором (analysis-ru) и маппингом полей для полнотекстового поиска. Реализована функция индексации (elasticsearch_service): каждый чанк документа сохраняется в Elasticsearch вместе с метаданными — file_name, page_number, chunk_id и text.

Настроена связка процесса загрузки, парсинга, сегментации и индексации в единый конвейер обработки документа (document_service), запускаемый после успешной загрузки файла (BE-06, BE-07).

ЭТАП 4: Реализация эндпоинта полнотекстового поиска (29.06.2026 – 30.06.2026)

Период: 2 дня

Задание: *Разработка эндпоинта полнотекстового поиска и формирование структуры ответа с ранжированием результатов.*

Содержание работы: Реализован эндпоинт GET /api/v1/search?q={query}, выполняющий запрос к Elasticsearch с использованием multi_match по полю text. Результаты поиска возвращаются в формате JSON с полями chunk_id, file_name, page, text и score (оценка релевантности), а совпавшие фрагменты сопровождаются подсветкой (highlight) для отображения на фронтенде. Реализован эндпоинт возврата списка загруженных документов с их названиями, датами загрузки и статусами. Валидация входных и выходных данных обеспечена через Pydantic-схемы, что гарантирует стабильный контракт API для фронтенд-части (BE-08, BE-09).

ЭТАП 5: Кеширование запросов и сохранение истории поиска (01.07.2026 – 02.07.2026)

Период: 2 дня

Задание: *Реализация кеширования частых поисковых запросов и сохранения истории поиска, оптимизация запросов.*

Содержание работы: Реализован модуль кеширования (cache) на базе Redis: результаты поисковых запросов сохраняются в кеше с временем жизни (TTL) 5 минут, и при повторном поступлении того же запроса ответ отдаётся из кеша, что снижает нагрузку на Elasticsearch и уменьшает время отклика.

Реализовано сохранение истории поисковых запросов в PostgreSQL (модель search_history). Проведена оптимизация запросов к Elasticsearch и профилирование бизнес-логики для обеспечения стабильной производительности под нагрузкой (BE-10).

ЭТАП 6: Документирование API и обработка ошибок (03.07.2026 – 04.07.2026)

Период: 2 дня

***Задание:** Документирование эндпоинтов через OpenAPI и реализация единообразной обработки ошибок с корректными HTTP-статусами.*

Содержание работы: Все эндпоинты задокументированы через OpenAPI 3.0; интерактивная документация Swagger UI доступна по адресу /docs. Реализована централизованная обработка исключений (exceptions), обеспечивающая возврат корректных HTTP-статусов: 200 OK при успешном выполнении, 400 Bad Request при ошибке валидации, 404 Not Found при отсутствии ресурса и 500 Internal Server Error при внутренней ошибке. Настроено структурированное логирование (logging_config). Код приведён в соответствие со стандартом PEP 8, публичные функции и классы снабжены описаниями параметров и возвращаемых значений.

ЭТАП 7: Экспорт метрик и финальная отладка (06.07.2026)

Период: 1 день

***Задание:** Подключение экспорта метрик для мониторинга, итоговая отладка серверной части и подготовка отчётной документации.*

Содержание работы: Подключён экспорт метрик приложения через prometheus-fastapi-instrumentator: эндпоинт /metrics предоставляет Prometheus данные о количестве запросов к /search и времени ответа. Реализован эндпоинт проверки работоспособности /health, используемый оркестратором и скриптом

инициализации. Выполнена итоговая отладка всех серверных модулей, проверена корректность обработки полного жизненного цикла документа — загрузка, парсинг, индексация, поиск. Сформирована финальная отчётность по серверной части проекта и составлен список приобретённых ИТ-компетенций.

ЗАКЛЮЧЕНИЕ

В ходе учебной практики были успешно выполнены все запланированные этапы работы. В рамках роли Backend Engineer спроектирована и реализована серверная часть микросервисной поисковой системы на FastAPI. Реализованы загрузка и валидация документов, извлечение текста из PDF и DOCX, сегментация и индексация в Elasticsearch с русскоязычным анализатором, полнотекстовый поиск с ранжированием и подсветкой результатов, кеширование через Redis и сохранение истории запросов в PostgreSQL. Все эндпоинты задокументированы через OpenAPI, обеспечена корректная обработка ошибок и экспорт метрик. Серверная часть покрыта тестами, задокументирована и полностью готова к эксплуатации.

Приобретённые навыки: разработка REST API на FastAPI, проектирование бизнес-логики и сервисного слоя, работа с реляционной БД PostgreSQL через асинхронный SQLAlchemy, интеграция с Elasticsearch (маппинг, анализаторы, multi_match, highlight), извлечение текста из PDF/DOCX (pdfplumber, python-docx), кеширование через Redis, валидация данных через Pydantic, документирование API (OpenAPI/Swagger), обработка исключений и логирование, соблюдение стандарта PEP 8, работа с Git.

Статистика: Общая продолжительность практики — 12 дней, количество этапов — 7, реализовано API-эндпоинтов: 4 (загрузка, поиск, список документов, health), разработано сервисных модулей: 7 (валидация, парсинг, сегментация, индексация, поиск, кеш, оркестрация обработки),

поддерживаемых форматов документов: 2 (PDF, DOCX), интеграций с внешними системами: 3 (PostgreSQL, Elasticsearch, Redis).

Ссылка на репозиторий: <https://github.com/JeTsEt627/Fieldwork.-2-nd-year-BPI2403>